

角色偏好与 互动边界管理

AstrBot 插件项目报告与测试指南

astrbot_plugin_preference_profile / 0.1.12

A0 独立验收通过

A1 实机测试待执行

让双方偏好有据可依，让关闭与边界真正生效。
面向项目负责人、测试朋友与测试环境维护者。

报告版本 1.0 · 2026-09-20

验收交付 da4e70a / v5-final

适用组合 插件 0.1.12 + AstrBot 4.28.0 / 4.26.0 对应宿主 v3 补丁

本报告汇总本地独立验收证据；真实 QQ、模型效果与朋友环境仍待 A1 验证。

项目结论与阅读导航

先了解可交付的成果，再按清单进入真实环境测试。

当前结论：本地独立验收已完成

最终交付 da4e70a / v5-final 的剩余 N2 问题已闭合。P0-P7 与 A0 已由 Codex 验收关闭；A1 为 Todo，可以开始准备与实测。

项目将原始“XP 管理”需求落成一套私聊偏好与互动边界管理能力：用户维护自己的档案，管理员维护 Bot 当前人格模板，规则综合双方状态后形成少量、本轮有效的表达指导。

已完成	仍待完成
身份与权限、双方偏好规则、持久化、管理命令、关闭/删除失效。	真实模型对方向、强度和节奏的表现，以及不同模型的一致性。
对应宿主补丁组合的归属、生命周期、隐私联动与交付重建验证。	测试 QQ 的私聊/群聊体验、朋友环境安装及重启停用表现。
双版本完整入口各 12 项通过；包、基线、日志与哈希一致。	云端部署、公开发布、许可选择及尚未验证的新版本组合。

阅读导航

读者	建议阅读
项目负责人	第 2-3 页：目标与范围；第 8-9 页：验收与工程结论；第 16 页：后续判定。
测试环境维护者	第 4-7 页：方案、边界、安装组合与命令；第 15 页：精确版本与交付清单。
参与测试的朋友	第 10-14 页：准备、16 个测试用例与结果记录模板。

证据口径：本报告以 2026-09-20 的最终独立验收材料为准。仓库部分文档保留早期阶段状态，不能用旧标题或历史统计替代本报告的固定候选结论。

项目目标与功能范围

双向、手动、私聊、可关闭，是首版的核心约束。

能力	本版行为
双方档案	用户档案与 Bot 当前人格模板分开存储；性别不决定主动/接受方向。
偏好维度	喜欢 / 中立 / 不喜欢 / 明确禁止；方向为主动 / 接受 / 双向；强度为 1-5。
标签管理	内置话题偏好、称呼方式、玩笑尺度、亲密度表达、互动节奏、语气风格；支持受限长度的自定义标签。
私聊命令	本人查看、增改、删除、关闭、清空；管理员配置总开关与当前人格模板。
请求内指导	在真实模型请求中加入临时参考，受条目数和字符预算约束；正常路径不因此增加一次模型调用。
协作联动	Relation Arc 提供只读关系节奏；Context Bridge 通过排除协议保护已启用偏好私聊轮次。

角色与权限

角色	可操作范围
普通用户	只操作自己的档案；个人开启仍受管理员总开关约束。
管理员	维护当前人格的 Bot 模板和总开关；没有通过普通命令读取他人私人档案的授权。
环境维护者	准备固定版本、补丁、日志与备份；数据库运维权限仍可能接触落盘数据。

首版范围

偏好来自本人声明或管理员模板。自动猜测、自动学习写入、管理员网页面板、公开发布和生产部署均不属于本次已交付验收范围。

技术方案与数据流

在正确主体、正确轮次中使用偏好，并能在失效时找到自己的内容。

身份键由平台实例、机器人、当前人格与真实用户组成。人格无法可靠解析时暂停该轮私人操作，避免退回错误主体。档案以 SQLite 保存，并用事务、revision 与 epoch 处理并发和关闭失效。

01 入口确认

私聊 + 管理员总开关 + 本人开启 + 人格解析

02 读取与协商

本人档案 / Bot 模板；共享排除协议；只读关系快照

03 规则决策

禁止与不喜欢优先；方向保留双方角色；计算强度上限

04 本轮提示

受限固定句式 + 原生临时文本块；按预算裁剪

05 运行时关联

宿主 v3 建立源对象到最终实例的弱关联；精确失效与回收

关闭、删除、停用如何传递

状态写入会主动触发失效清理。组装前按源对象身份移除；组装后依赖宿主来源映射定位本插件实例，避免按同文、前缀或位置误删其他插件的副本。组装等待中先失效、后建立实例的情况有补偿清理。

正常完成、失败、取消和停用后释放关联；多步 Agent 的中间回复不被当作终态提前回收。弱引用不额外延长运行时对象寿命。以上结论只适用于已验证的对应宿主补丁组合。

决策规则与隐私边界

规则引擎给出确定性约束，模型是否稳定遵守仍需实测。

输入组合	规则结果
任一方明确禁止或不喜欢	生成回避指导；即使另一方未设置，也不把限制当作无效。
双方喜欢	产生正向指导，上限取双方明确喜欢强度中的较低值。
喜欢 + 中立	可产生正向指导；中立既不抬升也不压低对方已声明强度。
喜欢 + 未设置；或双方中立	不生成正向指导。未设置不作为同意。
关系暂停 / 放缓	有效快照下，暂停移除正向指导；放缓把正向强度上限压到 2。
无关话题或明确示意停止	固定提示要求只在自然涉及时参考、停止即回到普通话题；其实际模型表现属于 A1。

三条需要分清的边界

- 临时提示与共享排除不同。** mark_as_temp 用于不写入宿主历史；Context Bridge 的捕获前排除协议另行保护私聊输入、回复和工具轨迹。协作插件在场但没有已验证协议时，私人偏好注入被禁用。
 - 关系不可用不等于全部偏好关闭。** Relation Arc 缺失、格式未知或读取异常时，关系联动不生效，独立偏好仍可运行。需要依赖暂停限制的测试必须先确认关系快照有效。
 - 关闭不等于撤回。** off / clear 停止后续读取与注入，并按合同处理尚未发送的在途内容；已发送给模型的内容、宿主旧历史和备份不会被本插件追溯删除。
- 数据保护边界：不宣称端到端保密；服务器或数据库维护人员仍可能读取落盘数据。测试采用合成标签，回传日志做脱敏。

测试环境与安装组合

给环境维护者：先核对版本和补丁，再交朋友试用。

本次通过的是组合

偏好插件 0.1.12 + AstrBot 4.28.0 或 4.26.0 的对应来源映射 v3 补丁。插件 ZIP 本身不含宿主修改。单独安装 ZIP 到原生宿主不属于本次通过的完整组合。

顺序	维护者操作	完成依据
1 固定输入	使用 da4e70a / v5-final 的 combo_manifest.json 和配套文件。	版本、提交、原始文件与补丁哈希匹配。
2 建立隔离	选择尚不存在且与来源不重叠的新测试目录；使用合成数据。	不清理已有目录，不改正在使用的宿主。
3 重建与核验	按对应宿主版本使用交付入口，从固定提交导出插件与协作件。	预检先于写入；完整源码集合和哈希通过。
4 配置真实测试	由环境负责人安装到测试实例，设置模型、测试账号与人格。	账号及密钥只在本地填写；记录组合信息。
5 默认关闭检查	先确认插件正常加载、总开关关闭，再按第10页开启正常样例。	管理命令可用；加载与操作记录可追溯。

交付入口的用途

rebuild_and_test.py 是固定组合的隔离重建与离线验证入口，不是朋友设备的一键生产部署器。其 --work 必须为新目录；已有目录会拒绝，不能靠自动清空继续。探针依赖也须按交付说明准备。

停用与回退

普通试用先用 /xp off 或管理员总开关关闭；需要回退安装时，停止测试实例并恢复测试前备份。宿主修改按精确原始文件清单还原、协作补丁按对应基线处理。不要将未知版本文件直接混配覆盖。

命令与配置速查

管理命令在私聊执行；模板作用于当前人格。

命令	用途
/xp help · /xp status	帮助与本人当前状态；/偏好 为中文别名组。
/xp on · /xp off	本人启用/关闭；不能突破管理员总开关。
/xp show [页码]	查看自己的条目。
/xp set <标签> <状态> [方向] [强度]	增减本人条目；状态、方向与强度分别校验。
/xp remove <标签>	删除本人单条记录。
/xp clear [确认码]	先请求一次性确认码，再按机器人返回的完整命令确认。
/xp admin switch on off	管理员总开关。
/xp admin stats	管理员查看脱敏统计。
/xp admin template show set remove clear	维护当前人格模板；set 的标签/状态/方向/强度与本人设置同类。

配置	默认值	含义
admin_enabled	false	管理员总开关默认关闭。
relation_link_enabled	true	尝试只读关系联动；不可用时不套用未知关系状态。
max_inject_items	6	单轮条目预算；配置可用范围 1-10。
max_inject_chars	600	总字符预算，包含归属标识；范围 100-2000。

输入范围：强度1-5；自定义标签2-16字；命令帮助显示的合法值优先。不把“保存成功”直接等同于模型效果已验证，实际效果按第12页做对照。

独立验收结果

最终候选在真实宿主代码路径上验证，模型和网络为可控替身。

核对项	4.28.0	4.26.0
完整入口验证项	12 / 12	12 / 12
场景/断言合计	87	87
正常 DONE / assistant 终态	4 / 4	4 / 4
完整寿命场景	5 / 5	5 / 5
stdout / stderr 日志文件	24	24
重算且一致的组合哈希	954	875
固定源码文件数	插件47 / 关系37 / 共享30	插件47 / 关系37 / 共享30
进程退出码	0	0

12 项由 boundary8、token12、历史50、映射4、E1终态4、m_rework4、寿命5组成。历史50细分为 corrected6、remaining6、composition9、terminal8、ownership4、lifecycle17。数字是不同测试组的实际口径，不等同于87个互不重叠的产品功能。

最后一项 N2 的闭合证据

反例	旧入口 614bfac	最终入口 da4e70a
错误补丁哈希 / 缺失blob 4.28.0, 两例	拒绝前已写入895文件；每例235个输出变更事件。	两例正确拒绝；0文件、0输出变更事件。
相同两例 4.26.0	拒绝前已写入816文件；每例211个输出变更事件。	两例正确拒绝；0文件、0输出变更事件。

旁路审计观察到新反例没有创建后再删除；没有应用补丁或启动测试。合法构建实际应用的字节与预检固定 blob 完全一致。交付另有13项 gates，含1项合法对照，退出0。

先前已接受的原生16脚本、每版264断言本轮未重跑。它们与本次补丁组合证据分列；真实QQ和实际模型仍未在A0中被替代验证。

工程收敛与当前限制

经过多轮复核，最终方案围绕真实接口与可重建证据收敛。

问题类别	最终处理与验收意义
身份与权限	统一真实私聊接口，命令与请求从同一会话解析人格；读取异常时拒绝不可信的私人操作。
生命周期	关闭/删除/配置写入主动失效；覆盖异步等待、多步Agent、中止、取消和正式停用；真实终态才释放。
归属与文本重建	宿主 v3 保留序列化快照语义，并建立源对象到最终实例的弱关联；复制不凭内容相等继承归属。
宿主兼容性	使用宿主原生文本类型，不覆盖全局类型注册；默认关闭时保持其他内容语义。
组合与交付	固定提交导出、补丁预检前移、应用同一字节、精确校验完整文件集合、记录实际导入路径和日志。

通过后仍保留的实际边界

- 版本有边界：**通过限定为4.28.0/4.26.0及对应v3；其他宿主版本、第三方Agent或新协作版本需要另验。
- 模型有随机性：**方向、强度和停止提示属于指导，不能由离线断言推出所有实际模型都稳定遵守。
- 取消有宿主因素：**宿主取消任务可能保留短期引用，不能把全部残留都归因于本插件，也不宣称无条件全局零引用。
- 交付不等于部署：**A0已经关闭；朋友设备配置、真实模型调用、QQ适配器行为、云端安装与公开发布仍需分别完成。

下一步保持范围清晰

进入A1收集实机证据。确有问题时，用固定版本、具体步骤和实际结果复现；不凭一次“回复像不对”就推翻已通过的内部生命周期结论。

A1 测试准备与正常样例

本页起为建议的执行方案；结果栏尚未填写。

分工	职责
环境负责人	确认固定组合、测试实例、模型参数与日志位置；处理安装与可恢复的回退。
参与测试的朋友	操作测试私聊/群聊、记录输入输出，不填真实敏感偏好。
Codex复核	对照证据判断V21/V22，区分模型效果、配置问题与实现缺陷。

开始前记录：测试日期、人员代号、宿主版本、补丁和插件提交、模型/供应方、采样参数、人格、启用的协作插件。准备第二个测试用户和一个测试群。管理员与朋友先切到同一测试人格。

管理员先在私聊设置

```
/xp admin switch on
/xp admin template set 语气风格 喜欢 双向 2
```

朋友再在私聊设置

```
/xp help
/xp on
/xp set 语气风格 喜欢 双向 2
/xp show
/xp status
```

用固定问题开始，例如“我想聊聊语气风格，请用轻松但克制的方式回应”。保存回复与配置。比较强度或方向时一次只改一个因素，使用同一人格下的新测试会话减少旧上下文干扰。

判定分两层

命令、权限与存储行为按明确结果判定；模型效果建议每组至少3次相同条件对照。仅凭回复外观无法证明内部注入是否发生，疑点交环境负责人查脱敏日志。

测试用例 01-05

基础操作、权限与删除；每例结果填写“通过 / 失败 / 待核实”。

A01 默认关闭与帮助

操作：新测试实例保持管理员总开关关闭；执行 help、status，再尝试本人on。

预期：管理命令正常；个人开启不能突破总开关。

记录：记录提示；普通聊天外观仅作参考，必要时核对注入日志。

A02 正常双向设置

操作：按第10页设置同一人格模板与本人条目，再执行show、status并提出固定问题。

预期：保存值准确，状态与实际开关一致；获得正常回复。

记录：保留版本、命令回复、模型回答。

A03 增改与单条删除

操作：把语气风格强度从2改为4，查看；执行 /xp remove 语气风格 后再查看。

预期：新值可见；单条移除后不再出现在本人档案中。

记录：仅测试自己的记录；记录修改前后条目。

A04 清空一次性确认

操作：先设置合成条目；/xp clear 获取确认码；试错码，再按新获取的有效码确认。

预期：未正确确认不清空；正确确认后 /xp show 不再显示本人原条目。

记录：使用机器人实时返回的确认码；记录已发送内容不受追溯删除。

A05 普通用户与管理员权限

操作：普通用户尝试 /xp admin template show；管理员只在私聊修改当前人格模板。

预期：普通用户不能执行管理员模板操作；模板与本人档案各自独立。

记录：不使用真实他人档案做探测；失败提示不得包含私人内容。

测试用例 06-10

主体隔离与规则效果；模型效果按对照样本判断。

A06 不同用户、不同人格

操作：用户甲保存合成标签；用户乙查看自己的档案；甲切换到另一测试人格再查看。

预期：不同主体不串档；无法确认人格时应暂停私人操作。

记录：记录人格和用户代号，不在报告中写真实账号。

A07 双方冲突取严格限制

操作：同一标签设为一方喜欢、另一方禁止；固定问题对照双方喜欢时的回答。

预期：禁止或不喜欢优先，不能因另一方喜欢而继续推进该维度。

记录：每组至少3次；如出现越界，保留具体样本并标记失败或待核实。

A08 未设置与中立区别

操作：移除一方同标签，保留另一方喜欢；再将空缺一方设置为中立，重新对照。

预期：未设置不产生正向指导；中立表示可接受，不等于未设置。

记录：单方禁止仍应回避，不能把它当“未成对所以忽略”。

A09 方向与强度对照

操作：双方分别设“主动/接受”，再互换；另在双向下比较强度1和4，一次只改一项。

预期：方向能区分是谁主动、谁接受；模型表现符合克制程度的相对变化。

记录：模型与参数一致；每组至少3次，方向不能绕过不升级话题的总约束。

A10 本人关闭与管理员关闭

操作：已设置状态下执行 /xp off；恢复后由管理员执行 /xp admin switch off。

预期：后续请求停止本插件偏好读取和注入；个人无法越过总关闭。

记录：优先检查新请求；已经发出的请求不要求撤回。

测试用例 11-16

真实QQ、协作、重启与停止场景。

A11 私聊到群聊的隔离

操作：私聊写入独特合成标签，再去测试群执行 /xp show 并提通用查询。

预期：不泄露私人标签、值、开启状态或私聊原文；群聊仅作通用引导。

记录：群消息不要包含待检私有文本，避免把自己提供的信息误判为泄漏。

A12 关系暂停与放缓

操作：确认Relation Arc版本和快照有效；用其已有入口设暂停或放缓后重复固定问题。

预期：有效暂停限制优先；放缓下表达克制。

记录：未装或快照不可用记“未执行/待核实”，不假装本项通过。

A13 普通话题与停止意愿

操作：在已有偏好下问代码、日程等无关问题；相关聊天中明确表示停止。

预期：普通话题不被强套偏好；停止后回到普通话题。

记录：采集模型实际表现，区分指导存在与模型是否遵守。

A14 重启后的持久化

操作：保存合成条目，重启测试实例，再以同用户、同人格查看。

预期：已保存条目按设计保留；关闭/开启状态符合重启前设置。

记录：记录实例和人格，排除误切配置导致的假丢档。

A15 停用与恢复

操作：在测试实例正式停用插件后继续新聊天；再启用并核对状态。

预期：停用后无新插件指导；恢复后权限和开关仍可管理。

记录：恢复后按样例重新验证，不默认所有场景自动通过。

A16 失败、流式与中止

操作：若宿主提供停止入口，在流式输出中停止；对可控失败后的下一轮做观察。

预期：后续新轮次正常，不串入旧轮次偏好或他人内容。

记录：无入口或无法构造时记待核实；已发送片段不作撤回要求。

结果记录与问题反馈

本页为可打印模板；填写实际结果后再判定A1。

环境字段	填写内容
测试日期 / 人员代号	
宿主 / 插件 / 补丁提交	
模型 / 参数 / 人格	
协作插件与版本	

用例	实际结果摘要	结论	证据编号
A01-A05	基础操作、权限、删除：_____	_____	_____
A06-A10	隔离、冲突、方向、开关：_____	_____	_____
A11-A13	QQ / 关系 / 普通话题：_____	_____	_____
A14-A16	重启、停用、中止：_____	_____	_____

一条有效的问题报告包含什么

- 标题：**发生了什么、在哪个版本和哪种聊天中发生。
- 复现：**前置开关、双方标签、人格、操作顺序及输入。
- 差异：**期望结果与实际结果分别写；附时间、样本和脱敏日志。
- 频率：**例如“同条件3次中2次出现”，不要只写“感觉无效”。
- 恢复：**关闭、换新会话或重启后是否恢复。

建议的测试处置

若出现跨用户/跨群隐私暴露、越权修改或数据丢失，先关闭测试实例中的偏好总开关，保留证据交复核。一般措辞效果不稳定先记录模型样本与参数，避免把主观风格差异直接定为工程缺陷。

回传只包含合成内容或脱敏摘要。真实私聊、数据库和凭据留本地；确需提供日志时先删除账号、密钥及私人内容。所有“未执行”项目继续保留，不计为通过。

交付清单与精确基线

维护者附录：短提交用于阅读，完整值用于核对。

组成	版本与完整提交
交付仓库	v5-final da4e70a90684f3654fcf93e961588943fc9e958c
偏好插件	0.1.12 7c99f5ad3538794f14b2171e23df96c57afe10bd
Relation Arc	913ca59036267de2bcc481b8910b5f6fc8044f91
Context Bridge	d8a7147e2a43c37b83781b92774afae2a254be60 加 0001 排除协议补丁

交付物

插件包：astrbot_plugin_preference_profile-0.1.12.zip
交付仓库：偏好管理-宿主来源映射原型-20260919
必要材料：combo_manifest.json、rebuild_and_test.py、host_patch_v3_428.diff / host_patch_v3_426.diff、对应 patched_host 目录、协作补丁与寿命探针。

SHA-256 校验值

插件 ZIP
68a53d263ae77c54f60f0768ed8c6f1d
918b33ab211980ca438e63d9cce29403

Context Bridge 0001 blob
925d23224fe35fa694f5cd71036ead5e
6f3de4e5202f1ca5c2ec27639959f0ad

宿主 v3 / 4.28.0 diff
0678045fdc2f7fed1b7189d84fe52670
53348fef38ea3a44a2e1c9ee2de1f27e

宿主 v3 / 4.26.0 diff
cb7f51ae1d7746cd828aab1b8c60420f
0200e7a609456f59a80f6ca8d4f3d874

上方每个哈希分两行排版，核对时按顺序连接。宿主原始文件、应用后文件及完整源码树哈希以机器可读清单为准。包共47文件、5目录条目；不包含朋友的账号配置或真实数据。

资料依据与下一步

以可追溯证据完成交接，以实际结果结束A1。

编号	资料来源与用途
S1	第十五轮独立验收报告_A0通过.md：2026-09-20最终裁定、精确组合与验收边界。
S2	同轮 final_verification.json、n2_preflight_repro.json、entry_428/426.json、各summary及logs：本文统计与行为证据。
S3	同轮 linear_readback.json：MIS-146至154为Done；MIS-155为Todo。
S4	插件7c99f5a源码：model、identity、store、policy、commands、prompt_builder、injection与配置schema，用于功能和规则说明。
S5	交付da4e70a的 combo_manifest.json、host_patch_v3_hashes.txt 与重建入口：精确输入、补丁与校验流程。
S6	02_朋友测试清单_A1.md：本报告实机步骤的基础；16项用例、重复样本与记录格式为报告补充的执行建议。

本地证据根目录：D:/第三方插件完善/
偏好管理-独立复核-da4e70a-20260920/。源码目录与交付仓库同处“第三方插件完善”下。以上为材料定位信息，不要求朋友具备相同磁盘路径。

A1 的建议完成标准

完成已适用的用例，保留全部未执行与待核实项；真实模型样本能够支撑对方向、强度、冲突与停止的判断；QQ隔离、主体隔离、重启停用具备实际证据；所有失败项已复现、修复或形成明确待处理结论。最终由Codex复核V21/V22，不能仅凭“模型回了一句正常的话”关闭任务。

当前行动

先由环境负责人准备已验证组合，再按第10-14页开展A1。管理员页面、本人确认后的偏好学习等后续扩展不并入本轮试用结论；公开发布与生产部署另行决策。

报告版本 1.0 · 编制日期 2026-09-20
实施协作：ZCode / GLM 5.3；规划、独立验收与报告整理：Codex。
报告整理期间未重新执行产品验收、未调用真实QQ/付费模型、未安装到朋友设备。